# K-Nearest-Neighbor

Jesús Roberto Dávila González

March 31, 2025

## 1 Introducción

K-Nearest-Neighbor es un algoritmo basado en instancia de tipo supervisado de Machine Learning. Puede usarse para clasificar nuevas muestras (valores discretos) o para predecir (regresión, valores continuos). Al ser un método sencillo, es ideal para introducirse en el mundo del Aprendizaje Automático. Sirve esencialmente para clasificar valores buscando los puntos de datos "más similares" (por cercanía) aprendidos en la etapa de entrenamiento (ver 7 pasos para crear tu ML) y haciendo conjeturas de nuevos puntos basado en esa clasificación. A diferencia de K-means, que es un algoritmo no supervisado y donde la "K" significa la cantidad de "grupos" (clusters) que deseamos clasificar, en K-Nearest Neighbor la "K" significa la cantidad de "puntos vecinos" que tenemos en cuenta en las cercanías para clasificar los "n" grupos-que ya se conocen de antemano, pues es un algoritmo supervisado-.

Es un método que simplemente busca en las observaciones más cercanas a la que se está tratando de predecir y clasifica el punto de interés basado en la mayoría de datos que le rodean. Como dijimos antes, es un algoritmo:

- Supervisado: esto -brevemente- quiere decir que tenemos etiquetado nuestro conjunto de datos de entrenamiento, con la clase o resultado esperado dada "una fila" de datos.
- Basado en Instancia: Esto quiere decir que nuestro algoritmo no aprende explícitamente un modelo (como por ejemplo en Regresión Logística o árboles de decisión). En cambio memoriza las instancias de entrenamiento que son usadas como "base de conocimiento" para la fase de predicción.

## 2 Metodología

Primero hacemos imports de librerías que utilizaremos para manejo de datos, gráficas y nuestro algoritmo.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import ListedColormap
import matplotlib.patches as mpatches
import seaborn as sb

%matplotlib inline
plt.rcParams['figure.figsize'] = (16, 9)
plt.style.use('ggplot')

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import classification_report
from sklearn.metrics import confusion_matrix
```

Cargamoselarchivo entrada csv con pandas, usando separador de punto ycoma,puesenlasreviews hay textos que usan coma. Con head(10) vemos los 10 primeros registros.

```
dataframe = pd.read_csv(r"reviews_sentiment.csv",sep=';')
dataframe.head(10)
```

| | Review Title | Review Text | wordcount | titleSentiment | textSentiment | Star Rating | sentimentValue |
|---|---|---|---|---|---|---|---|
| **0** | Sin conexión | Hola desde hace algo más de un mes me pone sin... | 23 | negative | negative | 1 | -0.486389 |
| **1** | faltan cosas | Han mejorado la apariencia pero no | 20 | negative | negative | 1 | -0.586187 |
| **2** | Es muy buena lo recomiendo | Andres e puto amoooo | 4 | NaN | negative | 1 | -0.602240 |
| **3** | Version antigua | Me gustana mas la version anterior esta es mas... | 17 | NaN | negative | 1 | -0.616271 |
| **4** | Esta bien | Sin ser la biblia.... Esta bien | 6 | negative | negative | 1 | -0.651784 |
| **5** | Buena | Nada del otro mundo pero han mejorado mucho | 8 | positive | negative | 1 | -0.720443 |
| **6** | De gran ayuda | Lo malo q necesita de ...,pero la app es muy buena | 23 | positive | negative | 1 | -0.726825 |
| **7** | Muy buena | Estaba más acostumbrado al otro diseño, pero e... | 16 | positive | negative | 1 | -0.736769 |
| **8** | Ta to guapa. | Va de escándalo | 21 | positive | negative | 1 | -0.765284 |
| **9** | Se han corregido | Han corregido muchos fallos pero el diseño es ... | 13 | negative | negative | 1 | -0.797961 |

Aprovechamos a ver un resumen estadístico de los datos:

```
dataframe.describe()
```

| | wordcount | Star Rating | sentimentValue |
|---|---|---|---|
| **count** | 257.000000 | 257.000000 | 257.000000 |
| **mean** | 11.501946 | 3.420233 | 0.383849 |
| **std** | 13.159812 | 1.409531 | 0.897987 |
| **min** | 1.000000 | 1.000000 | -2.276469 |
| **25%** | 3.000000 | 3.000000 | -0.108144 |
| **50%** | 7.000000 | 3.000000 | 0.264091 |
| **75%** | 16.000000 | 5.000000 | 0.808384 |
| **max** | 103.000000 | 5.000000 | 3.264579 |

Son 257 registros. Las estrellas lógicamente vemos que van del 1 al 5. La cantidad de palabras van de 1 sóla hasta 103. y las valoraciones de sentimiento están entre-2.27 y 3.26 con una media de 0,38 y a partir del desvío estándar podemos ver que la mayoría están entre 0,38-0,89 y 0,38+0,89.

Veamos unas gráficas simples y qué información nos aportan:

```
dataframe.hist()
plt.show()
```


Vemos que la distribución de "estrellas" no está balanceada... esto no es bueno. Convendría tener las mismas cantidades en las salidas, para no tener resultados "tendenciosos". Para este ejercicio lo dejaremos así, pero en la vida real, debemos equilibrarlos. La gráfica de Valores de Sentimientos parece bastante una campana movida levemente hacia la derecha del cero y la cantidad de palabras se centra sobre todo de 0 a 10. Veamos realmente cuantas Valoraciones de Estrellas tenemos:

```
print(dataframe.groupby('Star Rating').size())
```

```
Star Rating
1    37
2    24
3    78
4    30
5    88
dtype: int64
```

Con eso confirmamos que hay sobre todo de 3 y 5 estrellas. Y aqui una gráfica más bonita:

```
sb.factorplot('Star Rating',data=dataframe,kind="count", aspect=3)
```

```
<seaborn.axisgrid.FacetGrid at 0x10cea75f8>
```

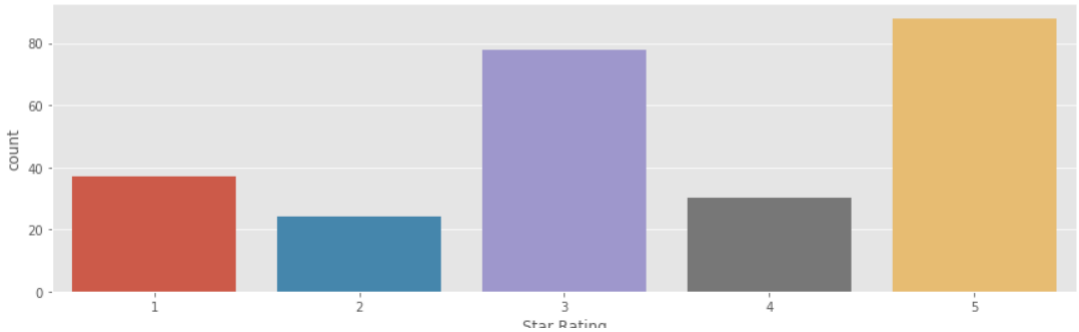


Graficamos mejor la cantidad de palabras y confirmamos que la mayoría están entre 1 y 10 palabras.

```
sb.factorplot('wordcount',data=dataframe,kind="count", aspect=3)
```

```
<seaborn.axisgrid.FacetGrid at 0x10ced6390>
```

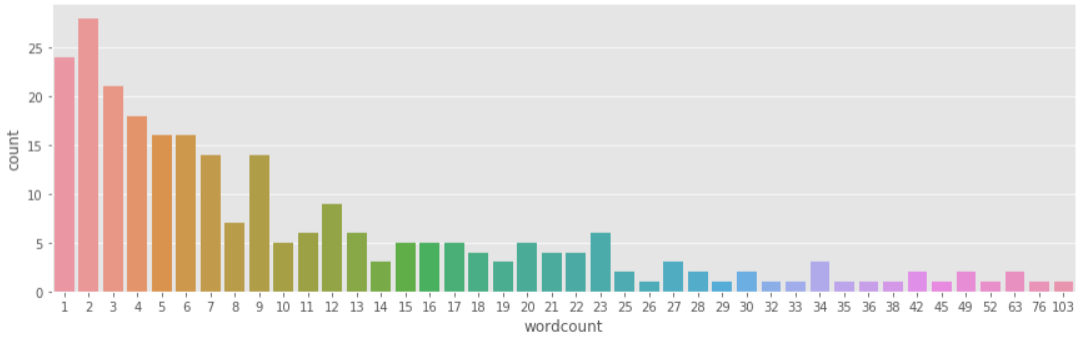


Preparamos las entradas Creamos nuestro X e y de entrada y los sets de entrenamiento y test

```
X = dataframe[['wordcount','sentimentValue']].values
y = dataframe['Star Rating'].values

X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=0)
scaler = MinMaxScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

Definimos el valor de k en 7 y creamos nuestro clasificador.

```
n_neighbors = 7

knn = KNeighborsClassifier(n_neighbors)
knn.fit(X_train, y_train)
print('Accuracy of K-NN classifier on training set: {:.2f}'
     .format(knn.score(X_train, y_train)))
print('Accuracy of K-NN classifier on test set: {:.2f}'
     .format(knn.score(X_test, y_test)))
```

```
Accuracy of K-NN classifier on training set: 0.90
Accuracy of K-NN classifier on test set: 0.86
```

# 3 Resultados

```
:
pred = knn.predict(X_test)
print(confusion_matrix(y_test, pred))
print(classification_report(y_test, pred))
```

```
[[ 9  0  1  0  0]
 [ 0  1  0  0  0]
 [ 0  1 17  0  1]
 [ 0  0  2  8  0]
 [ 0  0  4  0 21]]
             precision    recall  f1-score   support

          1       1.00      0.90      0.95        10
          2       0.50      1.00      0.67         1
          3       0.71      0.89      0.79        19
          4       1.00      0.80      0.89        10
          5       0.95      0.84      0.89        25

avg / total       0.89      0.86      0.87        65
```

Cómo se ve la puntuación F1 es del 87 por ciento, bastante buena. NOTA: recuerden que este es sólo un ejercicio para aprender y tenemos MUY pocos registros totales y en nuestro conjunto de test. Por ejemplo de 2 estrellas sólo tiene 1 valoración y esto es evidentemente insuficiente.

Ahora realizaremos la grafica con la clasificación obtenida, la que nos ayuda a ver fácilmente en donde caerán las predicciones. NOTA: al ser 2 features, podemos hacer la gráfica 2D y si fueran 3 podría ser en 3D. Pero para usos reales, podríamos tener más de 3 dimensiones y no importaría poder visualizarlo sino el resultado del algoritmo.

```
h = .02  # step size in the mesh

# Create color maps
cmap_light = ListedColormap(['#FFAAAA', '#ffcc99', '#ffffb3','#b3ffff','#c2f0c2'])
cmap_bold = ListedColormap(['#FF0000', '#ff9933','#FFFF00','#00ffff','#00FF00'])

# we create an instance of Neighbours Classifier and fit the data.
clf = KNeighborsClassifier(n_neighbors, weights='distance')
clf.fit(X, y)

# Plot the decision boundary. For that, we will assign a color to each
# point in the mesh [x_min, x_max]x[y_min, y_max].
x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                     np.arange(y_min, y_max, h))
Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])

# Put the result into a color plot
Z = Z.reshape(xx.shape)
plt.figure()
plt.pcolormesh(xx, yy, Z, cmap=cmap_light)

# Plot also the training points
plt.scatter(X[:, 0], X[:, 1], c=y, cmap=cmap_bold,
            edgecolor='k', s=20)
plt.xlim(xx.min(), xx.max())
plt.ylim(yy.min(), yy.max())

patch0 = mpatches.Patch(color='#FF0000', label='1')
patch1 = mpatches.Patch(color='#ff9933', label='2')
patch2 = mpatches.Patch(color='#FFFF00', label='3')
patch3 = mpatches.Patch(color='#00ffff', label='4')
patch4 = mpatches.Patch(color='#00FF00', label='5')
plt.legend(handles=[patch0, patch1, patch2, patch3,patch4])


plt.title("5-Class classification (k = %i, weights = '%s')"
          % (n_neighbors, 'distance'))

plt.show()
```

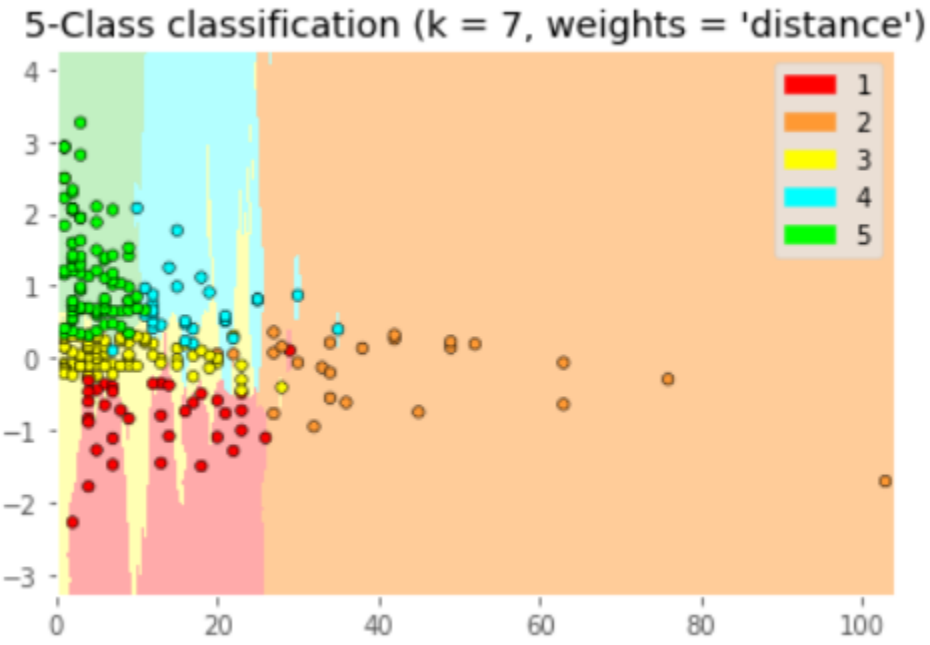

Antes vimos que asignamos el valor nNeighbors=7 como valor de “k” y obtuvimos buenos resultados.¿Pero de donde salió ese valor?. Pues realmente tuve que ejecutar este código que viene a continuación, donde vemos distintos valores k y la precisión obtenida.

```
k_range = range(1, 20)
scores = []
for k in k_range:
    knn = KNeighborsClassifier(n_neighbors = k)
    knn.fit(X_train, y_train)
    scores.append(knn.score(X_test, y_test))
plt.figure()
plt.xlabel('k')
plt.ylabel('accuracy')
plt.scatter(k_range, scores)
plt.xticks([0,5,10,15,20])
```

```
([<matplotlib.axis.XTick at 0x1a46946cf8>,
  <matplotlib.axis.XTick at 0x113ca5c18>,
  <matplotlib.axis.XTick at 0x113ca5e48>,
  <matplotlib.axis.XTick at 0x113aee2b0>,
  <matplotlib.axis.XTick at 0x113aee780>],
 <a list of 5 Text xticklabel objects>)
```

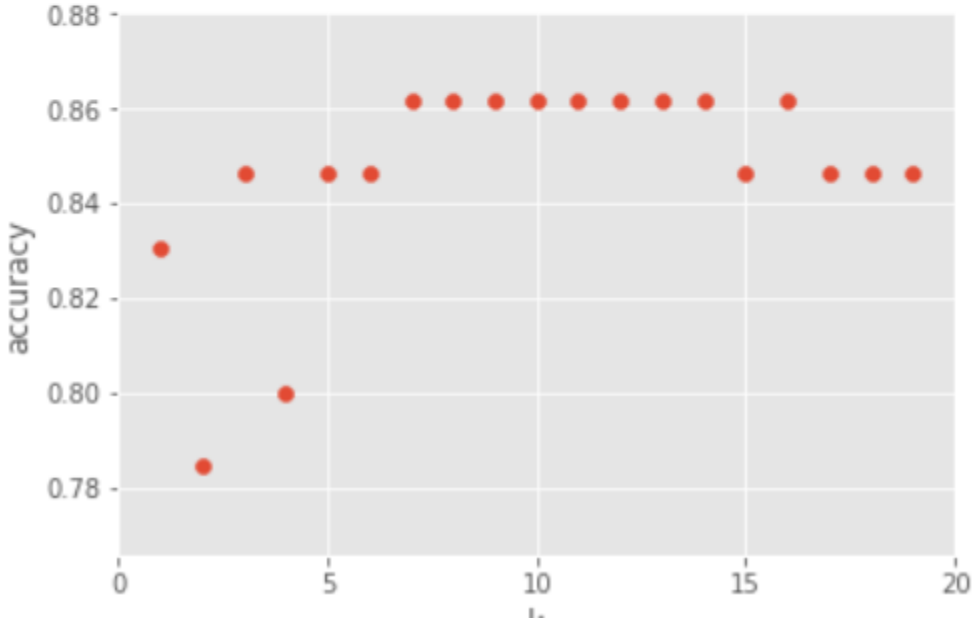


En la gráfica vemos que con valores k=7 a k=14 es donde mayor precisión se logra.

Ya tenemos nuestro modelo y nuestro valor de k. Ahora, lo lógico será usarlo! Pues supongamos que nos llegan nuevas reviews! veamos como predecir sus estrellas de 2 maneras. La primera:

```
print(clf.predict([[5, 1.0]]))
```

```
[5]
```

Este resultado nos indica que para 5 palabras y sentimiento 1, nos valorarán la app con 5 estrellas. Pero también podríamos obtener las probabilidades que de nos den 1, 2,3,4 o 5 estrellas con predictProba():

```
print(clf.predict_proba([[20, 0.0]]))
```

```
[[0.00381998 0.02520212 0.97097789 0.         0.        ]]
```

Aquí vemos que para las coordenadas 20, 0.0 hay 97 por ciento probabilidades que nos den 3 estrellas. Puedes comprobar en el gráfico anterior, que encajan en las zonas que delimitamos anteriormente.

# 4 Conclusión

En este ejercicio creamos un modelo con Python para procesar y clasificar puntos de un conjunto de entrada con el algoritmo k-Nearest Neighbor. Cómo su nombre en inglés lo dice, se evaluán los "k vecinos más cercanos" para poder clasificar nuevos puntos. Al ser un algoritmo supervisado debemos contar con suficientes muestras etiquetadas para poder entrenar el modelo con buenos resultados. Este algoritmo es bastante simple y -como vimos antes- necesitamos muchos recursos de memoria y cpu para mantener el dataset "vivo" y evaluar nuevos puntos. Esto no lo hace recomendable para conjuntos de datos muy grandes. En el ejemplo, sólo utilizamos 2 dimensiones de entrada para poder graficar y ver en dos dimensiones cómo se obtienen y delimitan los grupos. Finalmente pudimos hacer nuevas predicciones y a raíz de los resultados, comprender mejor la problemática planteada.